

Sesión 301

Inteligencia Artificial con Python

Instituto Politécnico Nacional
Centro de Investigación en Computo

M. Alan Badillo Salas

alan@nomadacode.com

6 de junio de 2026

Resumen

En esta tercera semana del curso consolidamos el estudio de la curva logística para cerrar el dominio del perceptrón y dar paso a la neurona artificial. Hasta ahora debemos tener claro el concepto de la regresión lineal y extender los resultados del predictor lineal hacia la curva logística, la cual busca transformar el espacio de respuesta para pasar del espacio abierto $(-\infty, \infty)$ al espacio cerrado $(0, 1)$ en la respuesta $\hat{y}$, llegando así al *Problema de la Clasificación Binaria*.

Introducción

El modelo de regresión lineal nos ha permitido entender como una matriz de características X y un vector de parámetros o pesos de ajuste (coeficientes de regresión) β diseñan una matriz extendida en la primera columna como 1s (unos) para considerar el bias y formar el **Predictor Lineal** $X \cdot \beta$. Este predictor lineal es la base de la regresión lineal y fija la respuesta lineal como una combinación entre los datos observados X y pesos desconocidos que actúan como ponderadores que indican el efecto o importancia de cada característica en promedio (pendiente). Al combinar muchos pesos y las diversas características tenemos un hiperplano formado por el predictor lineal y supondremos que la respuesta se comporta similar a ese hiperplano, haciendo que en una dimensión se vea como una recta y en dos dimensiones de características como un plano.

Sin embargo el predictor lineal ocupará todo el espacio, dando respuestas abiertas en $(-\infty, \infty)$, por lo que determinaremos cómo colapsar las respuestas a una predicción cerrada en el espacio $(0, 1)$ mediante la curva logística.

En estas notas de la sesión, revisaremos tres puntos principales de la *Curva Logística* y el (*Perceptrón*), que serán las bases para construir neuronas artificiales:

1. El *Problema de la Clasificación Binaria*
2. La *Curva Logística*
3. Las *Métricas de Validación*

Con esto, podremos construir de forma natural un modelo de neurona artificial, extendiendo los conceptos del perceptrón.

1. El *Problema de la Clasificación Binaria*

El *Problema de la Clasificación Binaria* consiste en predecir una respuesta que se comporta de forma binaria, es decir, las observaciones sobre y son cero o uno (0 o 1).

$$y \in \{0, 1\}^n \quad (1)$$

Así cada respuesta que podrían explicar las características vivirá en un espacio cerrado de 0 y 1 que se conoce como el espacio *simplex* para la respuesta.

1.1. Ejemplo 1 - Supervivencia en el Titanic

El conjunto de datos del Titanic contine características sobre los pasajeros y una respuesta binaria sobre su supervivencia, encontraremos las siguientes columnas principales:

- **Survived** - Binaria, indica si el pasajero sobrevive (respuesta)
- **Pclass** - Discreta, representa la clase de pase de abordaje (1 - primera clase, 2 - segunda clase, 3 - tercera clase), esto se relaciona con comodidades y atenciones al pasajero (costo o lujo del ticket y que se permitió el pasajero)
- **Age** - Discreta, indica la edad del pasajero, con valores atípicos y nulos, la media era de 29 años aproximadamente
- **Sex** - Binaria no codificada, indica si es hombre (male) o mujer (female)

- **SibSp** - Discreta, indica el número de hermanos y esposo con los que se viajaba (siblings and spouses)
- **Parch** - Discreta, indica el número de padres e hijos con los que viajaba acompañado (parents and children)
- **Cabin** - Texto, indica nulo si no se tenía una cabina o el nombre de la cabina

Además otras columnas como *Fare* (tarifa), *Ticket* (boleto) y *Embarked* (puerto), podrían adicionar mayor información.

Con estas columnas podríamos diseñar 6 características que abstraigan lo más importante de un pasajero, como si viajaba en primera clase, si viajaba en segunda clase, si era mujer, la edad normalizada (la edad menos la edad promedio entre la desviación estándar de la edad), el total de familiares ($SibSp + Parch$) y si tenía una cabina.

```

1 import numpy
2 import pandas
3
4 from matplotlib import pyplot
5 import seaborn
6
7 titanic = pandas.read_csv("../conjuntos/titanic.csv")
8
9 y = titanic["Survived"]
10
11 x1 = (titanic["Pclass"] == 1).astype(int)
12 x1 = x1.fillna(x1.median())
13 x2 = (titanic["Pclass"] == 2).astype(int)
14 x2 = x2.fillna(x2.median())
15 x3 = (titanic["Sex"] == "female").astype(int)
16 x3 = x3.fillna(x3.median())
17 x4 = (
18     (titanic["Age"] - titanic["Age"].mean()) /
19     titanic["Age"].std()
20 )
21 x4 = x4.fillna(x4.median())
22 x5 = titanic["SibSp"] + titanic["Parch"]
23 x5 = x5.fillna(x5.median())
24 x6 = ~titanic["Cabin"].isna()
25 x6 = x6.fillna(x6.median())

```

Antes de construir el cubo de datos X y ajustar el modelo $\hat{y} = \phi(X \cdot \beta)$, analicemos si cada una de las características que proponemos, tiene alguna influencia con la respuesta, es decir, la respuesta logra explicar una ruptura entre los valores que tomará la característica (piensa por ejemplo, en como cambia la supervivencia si se pertenecía a la primera clase o dada la edad).

1.1.1. Pertenecer a la primera clase

En la **Figura 1** se observa que cuando se es de primera clase, son poco más los que sobreviven (naranja) que los que no sobreviven (azul), contrario a cuando no se es de primera clase, donde la no-supervivencia supera por mucho a la supervivencia.




Figura 1: Efecto de la supervivencia si se pertenece a la primera clase (x_1)

Es primera clase: 216 de 891 (24.2%)

No es primera clase: 675 de 891 (75.8%)

Sobreviven primera clase: 136 de 891 (15.3%)

No sobreviven primera clase: 80 de 891 (9.0%)

Sobreviven y son primera clase: 136 de 342 (39.8%)

Sobreviven y no son primera clase: 206 de 342 (60.2%)

No sobreviven y son primera clase: 80 de 549 (14.6%)

No sobreviven y no son primera clase: 469 de 549 (85.4%)

Chances de sobrevivir primera clase: 2.73

Chances de sobrevivir global: 0.62

Un pasajero de primera clase tendrá casi 3 veces más oportunidades de sobrevivir que de no sobrevivir, es decir, de los pasajeros que sobreviven 136 de 342 son de primera clase, y de los que no sobreviven 80 de 549 son de primera clase, esto significa que casi dos quintas partes de los que sobreviven son de primera clase (39,8%), mientras que solo cerca una séptima parte de los que no sobreviven son de primera clase (14,6%), lo que significa que $2,7 \approx 39,8/14,6$ son las oportunidades adicionales que tiene alguien de sobrevivir siendo de primera clase (respecto a los que no sobreviven), o en términos simples, por cada 1 pasajero de primera clase que no sobrevive, 2.7 si lo hacen (chances 2.7:1 de sobrevivir).

1.1.2. Pertenecer a la segunda clase

En la **Figura 2** se observa que cuando se es de segunda clase, se podría pensar que la región azul supera a la naranja y entonces para la segunda clase se pensaría que sobreviven menos que los que no sobreviven. Pero estas densidades pueden ser engañosas, ya que la lectura clave es: ¿Será que la proporción de los que no sobreviven que son de segunda clase y los que no lo son, supera a la proporción entre los que sobreviven y son de segunda clase y los que no lo son? Esto demostraría que solo una pequeña parte de los que no sobreviven se carga a la derecha, mientras una mayor parte de los que si sobreviven se carga a la derecha también (1.44 veces mayor).

Es segunda clase: 184 de 891 (20.7%)

No es segunda clase: 707 de 891 (79.3%)

Sobreviven segunda clase: 87 de 891 (9.8%)

No sobreviven segunda clase: 97 de 891 (10.9%)

Sobreviven y son segunda clase: 87 de 342 (25.4%)

Sobreviven y no son segunda clase: 255 de 342 (74.6%)

No sobreviven y son segunda clase: 97 de 549 (17.7%)

No sobreviven y no son segunda clase: 452 de 549 (82.3%)

Chances de sobrevivir segunda clase: 1.44

Chances de sobrevivir global: 0.62




Figura 2: Efecto de la supervivencia si se pertenece a la segunda clase (x_2)

Analizando de forma similar, vemos que los de segunda clase tienen solo 1.44 oportunidades de sobrevivir (respecto a los que no sobreviven dentro de la misma clase). Esto aunque más bajo que la primera clase, indica que aún así la supervivencia es más alta que la no supervivencia.

1.1.3. Pertenecer a la tercera clase

En la **Figura 3** se observa el análisis similar para la tercera clase (no ser primera clase y tampoco ser segunda clase). Aquí vemos claramente como se invierte de supervivencia a no-supervivencia si se es de la tercera clase.

Es tercera clase: 491 de 891 (55.1%)

No es tercera clase: 400 de 891 (44.9%)

Sobreviven tercera clase: 119 de 891 (13.4%)

No sobreviven tercera clase: 372 de 891 (41.8%)

Sobreviven y son tercera clase: 119 de 342 (34.8%)

Sobreviven y no son tercera clase: 223 de 342 (65.2%)

No sobreviven y son tercera clase: 372 de 549 (67.8%)

No sobreviven y no son tercera clase: 177 de 549 (32.2%)




Figura 3: Efecto de la supervivencia si se pertenece a la tercera clase $((1 - x_1) \cdot (1 - x_2))$

Chances de sobrevivir tercera clase: 0.51

Chances de sobrevivir global: 0.62

Analizando las oportunidades de sobrevivir siendo de la tercera clase, incluso vemos que está por debajo de la supervivencia global (0.62 oportunidades de sobrevivir o 1.6 de no sobrevivir). Su inverso de no sobrevivir tendría $1.96 \approx \frac{1}{0.51}$, que indica que un pasajero tendrá 1,96 más oportunidades de no sobrevivir si es de tercera clase, respecto a otro de tercera clase también. Lectura rápida: Siendo de tercera clase casi 2 de 3 pasajeros no sobrevivieron (1.96:1 de no-sobrevivir o 0.51:1 de sobrevivir). El valor mayor a 1 (si es necesario calcular el inverso), siempre será más fácil de explicar, no es lo mismo decir, por cada 1.51 pasajeros de tercera clase, solo el 0.51 sobrevivirá, a decir, por cada 2.96 pasajeros de tercera clase, 1.96 no sobrevivirá (o en términos cerrados), de cerca de cada 3 pasajeros de tercera clase, 2 no sobrevivirán.

Podemos resumir las oportunidades de sobrevivir como en **Figura 4**.

Chances de supervivencia por clase del pasajero

Clase	Chances (Sobrevivir)	Inverso (No sobrevivir)
Todas	0.62	1.61
Primera	2.73	0.37
Segunda	1.44	0.69
Tercera	0.51	1.96

Figura 4: Tabla de resumen de las oportunidades o chances de supervivencia dada en pasajeros con distinta clase de viaje

Bibliografía

- Géron, A. (2023). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3.^a ed.). O'Reilly Media.
- Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media.
- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter (3.^a ed.). O'Reilly Media.
- Grus, J. (2019). Data Science from Scratch: First Principles with Python (2.^a ed.). O'Reilly Media.

Nota: Consulta el libro de Python for Data Analysis de Wes McKinney.