

Sesión 301

Inteligencia Artificial con Python

Instituto Politécnico Nacional
Centro de Investigación en Computo

M. Alan Badillo Salas

alan@nomadacode.com

11 de junio de 2026

Resumen

En esta tercera semana del curso consolidamos el estudio de la curva logística para cerrar el dominio del perceptrón y dar paso a la neurona artificial. Hasta ahora debemos tener claro el concepto de la regresión lineal y extender los resultados del predictor lineal hacia la curva logística, la cual busca transformar el espacio de respuesta para pasar del espacio abierto $(-\infty, \infty)$ al espacio cerrado $(0, 1)$ en la respuesta $\hat{y}$, llegando así al *Problema de la Clasificación Binaria*.

Introducción

El modelo de regresión lineal nos ha permitido entender como una matriz de características X y un vector de parámetros o pesos de ajuste (coeficientes de regresión) β diseñan una matriz extendida en la primera columna como 1s (unos) para considerar el bias y formar el **Predictor Lineal** $X \cdot \beta$. Este predictor lineal es la base de la regresión lineal y fija la respuesta lineal como una combinación entre los datos observados X y pesos desconocidos que actúan como ponderadores que indican el efecto o importancia de cada característica en promedio (pendiente). Al combinar muchos pesos y las diversas características tenemos un hiperplano formado por el predictor lineal y supondremos que la respuesta se comporta similar a ese hiperplano, haciendo que en una dimensión se vea como una recta y en dos dimensiones de características como un plano.

Sin embargo el predictor lineal ocupará todo el espacio, dando respuestas abiertas en $(-\infty, \infty)$, por lo que determinaremos cómo colapsar las respuestas a una predicción cerrada en el espacio $(0, 1)$ mediante la curva logística.

En estas notas de la sesión, revisaremos tres puntos principales de la *Curva Logística* y el (*Perceptrón*), que serán las bases para construir neuronas artificiales:

1. El *Problema de la Clasificación Binaria*
2. La *Curva Logística*
3. Las *Métricas de Validación*

Con esto, podremos construir de forma natural un modelo de neurona artificial, extendiendo los conceptos del perceptrón.

1. El *Problema de la Clasificación Binaria*

El *Problema de la Clasificación Binaria* consiste en predecir una respuesta que se comporta de forma binaria, es decir, las observaciones sobre y son cero o uno (0 o 1).

$$y \in \{0, 1\}^n \quad (1)$$

Así cada respuesta que podrían explicar las características vivirá en un espacio acotado de 0 y 1 relacionado con un espacio binario o probabilístico.

Importante: Para estudiar el efecto de las características sobre la respuesta, usaremos mal el término de chances y oportunidades, los cuales no estarán relacionados a los *odds* o los *odds ratios* que se conocen como momios y tienen un significado más específico donde $OR = \frac{p}{1-p}$, pero que servirá de intuición para determinar como las razones entre dos probabilidades agrupadas pueden mostrar una influencia en la tasa que se eleva o contrae en las oportunidades derivadas de las probabilidades entre los grupos.

1.1. Ejemplo 1 - Supervivencia en el Titanic

El conjunto de datos del Titanic contine características sobre los pasajeros y una respuesta binaria sobre su supervivencia, encontraremos las siguientes columnas principales:

- **Survived** - Binaria, indica si el pasajero sobrevive (respuesta)

- **Pclass** - Discreta, representa la clase de pase de abordaje (1 - primera clase, 2 - segunda clase, 3 - tercera clase), esto se relaciona con comodidades y atenciones al pasajero (costo o lujo del ticket y que se permitió el pasajero)
- **Age** - Discreta, indica la edad del pasajero, con valores atípicos y nulos, la media era de 29 años aproximadamente
- **Sex** - Binaria no codificada, indica si es hombre (male) o mujer (female)
- **SibSp** - Discreta, indica el número de hermanos y esposo con los que se viajaba (siblings and spouses)
- **Parch** - Discreta, indica el número de padres e hijos con los que viajaba acompañado (parents and children)
- **Cabin** - Texto, indica nulo si no se tenía una cabina o el nombre de la cabina

Además otras columnas como *Fare* (tarifa), *Ticket* (boleto) y *Embarked* (puerto), podrían adicionar mayor información.

Con estas columnas podríamos diseñar 6 características que abstraigan lo más importante de un pasajero, como si viajaba en primera clase, si viajaba en segunda clase, si era mujer, la edad normalizada (la edad menos la edad promedio entre la desviación estándar de la edad), el total de familiares ($SibSp + Parch$) y si tenía una cabina.

```

1  import numpy
2  import pandas
3
4  from matplotlib import pyplot
5  import seaborn
6
7  titanic = pandas.read_csv("../..conjuntos/titanic.csv")
8
9  y = titanic["Survived"]
10
11 x1 = (titanic["Pclass"] == 1).astype(int)
12 x1 = x1.fillna(x1.median())
13 x2 = (titanic["Pclass"] == 2).astype(int)
14 x2 = x2.fillna(x2.median())
15 x3 = (titanic["Sex"] == "female").astype(int)
16 x3 = x3.fillna(x3.median())
17 x4 = (

```

```

18     (titanic["Age"] - titanic["Age"].mean()) /
19     titanic["Age"].std()
20 )
21 x4 = x4.fillna(x4.median())
22 x5 = titanic["SibSp"] + titanic["Parch"]
23 x5 = x5.fillna(x5.median())
24 x6 = ~titanic["Cabin"].isna()
25 x6 = x6.fillna(x6.median())

```

Antes de construir el cubo de datos X y ajustar el modelo $\hat{y} = \phi(X \cdot \beta)$, analicemos si cada una de las características que proponemos, tiene alguna influencia con la respuesta, es decir, la respuesta logra explicar una ruptura entre los valores que tomará la característica (piensa por ejemplo, en como cambia la supervivencia si se pertenecía a la primera clase o dada la edad).

1.1.1. Pertenecer a la primera clase

En la **Figura 1** se observa que cuando se es de primera clase, son poco más los que sobreviven (naranja) que los que no sobreviven (azul), contrario a cuando no se es de primera clase, donde la no-supervivencia supera por mucho a la supervivencia.




Figura 1: Efecto de la supervivencia si se pertenece a la primera clase (x_1)

Es primera clase: 216 de 891 (24.2%)
No es primera clase: 675 de 891 (75.8%)

Sobreviven primera clase: 136 de 891 (15.3%)
No sobreviven primera clase: 80 de 891 (9.0%)

Sobreviven y son primera clase: 136 de 342 (39.8%)
Sobreviven y no son primera clase: 206 de 342 (60.2%)
No sobreviven y son primera clase: 80 de 549 (14.6%)
No sobreviven y no son primera clase: 469 de 549 (85.4%)

Chances de sobrevivir primera clase: 2.73
Chances de sobrevivir global: 0.62

Un pasajero de primera clase tendrá casi 3 veces más oportunidades de sobrevivir que de no sobrevivir, es decir, de los pasajeros que sobreviven 136 de 342 son de primera clase, y de los que no sobreviven 80 de 549 son de primera clase, esto significa que casi dos quintas partes de los que sobreviven son de primera clase (39,8 %), mientras que solo cerca una séptima parte de los que no sobreviven son de primera clase (14,6 %), lo que significa que $2,7 \approx 39,8/14,6$ son las oportunidades adicionales que tiene alguien de sobrevivir siendo de primera clase (respecto a los que no sobreviven), o en términos simples, por cada 1 pasajero de primera clase que no sobrevive, 2.7 si lo hacen (chances 2.7:1 de sobrevivir).

1.1.2. Pertenecer a la segunda clase

En la **Figura 2** se observa que cuando se es de segunda clase, se podría pensar que la región azul supera a la naranja y entonces para la segunda clase se pensaría que sobreviven menos que los que no sobreviven. Pero estas densidades pueden ser engañosas, ya que la lectura clave es: ¿Será que la proporción de los que no sobreviven que son de segunda clase y los que no lo son, supera a la proporción entre los que sobreviven y son de segunda clase y los que no lo son? Esto demostraría que solo una pequeña parte de los que no sobreviven se carga a la derecha, mientras una mayor parte de los que si sobreviven se carga a la derecha también (1.44 veces mayor).

Es segunda clase: 184 de 891 (20.7%)
No es segunda clase: 707 de 891 (79.3%)

Sobreviven segunda clase: 87 de 891 (9.8%)
No sobreviven segunda clase: 97 de 891 (10.9%)




Figura 2: Efecto de la supervivencia si se pertenece a la segunda clase (x_2)

Sobreviven y son segunda clase: 87 de 342 (25.4%)
 Sobreviven y no son segunda clase: 255 de 342 (74.6%)
 No sobreviven y son segunda clase: 97 de 549 (17.7%)
 No sobreviven y no son segunda clase: 452 de 549 (82.3%)

Chances de sobrevivir segunda clase: 1.44
 Chances de sobrevivir global: 0.62

Analizando de forma similar, vemos que los de segunda clase tienen solo 1.44 oportunidades de sobrevivir (respecto a los que no sobreviven dentro de la misma clase). Esto aunque más bajo que la primera clase, indica que aún así la supervivencia es más alta que la no supervivencia.

1.1.3. Pertener a la tercera clase

En la **Figura 3** se observa el análisis similar para la tercera clase (no ser primera clase y tampoco ser segunda clase). Aquí vemos claramente como se invierte de supervivencia a no-supervivencia si se es de la tercera clase.

Es tercera clase: 491 de 891 (55.1%)
 No es tercera clase: 400 de 891 (44.9%)




Figura 3: Efecto de la supervivencia si se pertenece a la tercera clase $((1 - x_1) \cdot (1 - x_2))$

Sobreviven tercera clase: 119 de 891 (13.4%)

No sobreviven tercera clase: 372 de 891 (41.8%)

Sobreviven y son tercera clase: 119 de 342 (34.8%)

Sobreviven y no son tercera clase: 223 de 342 (65.2%)

No sobreviven y son tercera clase: 372 de 549 (67.8%)

No sobreviven y no son tercera clase: 177 de 549 (32.2%)

Chances de sobrevivir tercera clase: 0.51

Chances de sobrevivir global: 0.62

Analizando las oportunidades de sobrevivir siendo de la tercera clase, incluso vemos que está por debajo de la supervivencia global (0.62 oportunidades de sobrevivir o 1.6 de no sobrevivir). Su inverso de no sobrevivir tendría $1.96 \approx \frac{1}{0.51}$, que indica que un pasajero tendrá 1,96 más oportunidades de no sobrevivir si es de tercera clase, respecto a otro de tercera clase también. Lectura rápida: Siendo de tercera clase casi 2 de 3 pasajeros no sobrevivieron (1.96:1 de no-sobrevivir o 0.51:1 de sobrevivir). El valor mayor a 1 (si es necesario calcular el inverso), siempre será más fácil de explicar, no es lo mismo decir, por cada 1.51 pasajeros de tercera clase, solo el 0.51 sobrevivi-

rá, a decir, por cada 2.96 pasajeros de tercera clase, 1.96 no sobrevivirá (o en términos cerrados), de cerca de cada 3 pasajeros de tercera clase, 2 no sobrevivirán.

Podemos resumir las oportunidades de sobrevivir por clase del pasajero como en la **Figura 4**.

Chances de supervivencia por clase del pasajero		
Clase	Chances (Sobrevivir)	Inverso (No sobrevivir)
Todas	0.62	1.61
Primera	2.73	0.37
Segunda	1.44	0.69
Tercera	0.51	1.96

Figura 4: Tabla de resumen de las oportunidades o chances de supervivencia dada en pasajeros con distinta clase de viaje

1.1.4. Ser mujer

En la **Figura 5** se observan más claramente los chances u oportunidades de supervivencia, siendo y no siendo mujer, por ejemplo, de las personas que sobreviven, se observa que cerca de 2 a 1 eran mujeres, y de las que no sobreviven se vuelven como 5 a 1 de no ser mujer.

Son mujeres: 314 de 891 (35.2%)

No son mujeres: 577 de 891 (64.8%)

Sobreviven mujeres: 233 de 891 (26.2%)

No sobreviven mujeres: 81 de 891 (9.1%)

Sobreviven y son mujeres: 233 de 342 (68.1%)

Sobreviven y no son mujeres: 109 de 342 (31.9%)

No sobreviven y son mujeres: 81 de 549 (14.8%)

No sobreviven y no son mujeres: 468 de 549 (85.2%)

Chances de sobrevivir mujeres: 4.62




Figura 5: Efecto de la supervivencia si se es mujer (x_3)

Chances de sobrevivir global: 0.62

Siendo mujer la proporción de mujeres entre sobrevivientes es aproximadamente 4.62 veces la proporción de mujeres entre no sobrevivientes, se podría pensar, aunque con cuidado, que por cada mujer que no sobrevive, cerca de 4.62 mujeres sobreviven, o visto más compacto, por cada dos mujeres que no sobreviven, 9 de ellas si lo hacen (1:4.62 aproximadamente 2:9).

Nota: Debemos aclarar nuevamente que las oportunidades que se mencionan son más bien razones calculadas entre las proporciones indicadas, por ejemplo, ser mujer y sobrevivir entre ser mujer y no sobrevivir.

1.1.5. No ser mujer (ser hombre)

En la **Figura 6** se observa de forma inversa cuando la característica de ser mujer se niega, para entender su contraparte.

Son hombres: 577 de 891 (64.8%)

No son hombres: 314 de 891 (35.2%)

Sobreviven hombres: 109 de 891 (12.2%)

No sobreviven hombres: 468 de 891 (52.5%)




Figura 6: Efecto de la supervivencia si no se es mujer ($1 - x_3$)

Sobreviven y son hombres: 109 de 342 (31.9%)

Sobreviven y no son hombres: 233 de 342 (68.1%)

No sobreviven y son hombres: 468 de 549 (85.2%)

No sobreviven y no son hombres: 81 de 549 (14.8%)

Chances de sobrevivir hombres: 0.37

Chances de sobrevivir global: 0.62

Siendo hombre se tienen chances contrarios a ser mujer, prácticamente la supervivencia es más baja que la global (1:2.7 chances de no sobrevivir siendo hombre).

Podemos resumir las oportunidades de sobrevivir siendo y no siendo mujer como en la **Figura 7**.

1.1.6. Por edad

En la **Figura 8** se observa que la no supervivencia se agudiza en el centro (edad promedio) y si hay un efecto de equilibrio en los extremos, incluyo siendo mayor la supervivencia en niños.

Edad media: 29.70 (14.53)

Sigma: 1

Chances de supervivencia por sexo

Clase	Chances (Sobrevivir)	Inverso (No sobrevivir)
Todas	0.62	1.61
Mujeres	4.62	0.22
Hombres	0.37	2.70

Figura 7: Tabla de resumen de las oportunidades o chances de supervivencia dado si se es o no mujer




Figura 8: Efecto de la supervivencia por edad (x_4)

```
=====
Chances sobrevive abajo: 159 a 319 (0.50)
Chances no sobrevive abajo: 319 a 159 (2.01)
-----
Chances sobrevive arriba: 91 a 124 (0.73)
Chances no sobrevive arriba: 124 a 91 (1.36)

Sigma: 2
```

```

=====
Chances sobrevive abajo: 48 a 34 (1.41)
Chances no sobrevive abajo: 34 a 48 (0.71)
-----
Chances sobrevive arriba: 36 a 51 (0.71)
Chances no sobrevive arriba: 51 a 36 (1.42)

Sigma: 3
=====
Chances sobrevive abajo: 1 a 0 (inf)
Chances no sobrevive abajo: 0 a 1 (0.00)
-----
Chances sobrevive arriba: 6 a 20 (0.30)
Chances no sobrevive arriba: 20 a 6 (3.33)

```

Para analizar la supervivencia en una escala como la edad que es continua, podemos alejarnos de la media cierto valor, por ejemplo, la desviación estándar (σ). De esta manera podemos observar como cambia la supervivencia debajo y arriba de la media, alejándose una σ distancia (lo podemos interpretar como bloques similares a los cuantiles, pero no uniformes, sino normales).

Podemos resumir las oportunidades de sobrevivir por bloque de edad como en la **Figura 9**.

Chances de supervivencia por edad ($\mu \approx 29.7, \sigma \approx 14.5$)		
Sigma	Chances Abajo (Sobrevive / No sobrevive)	Chances Arriba (Sobrevive / No sobrevive)
1	0.50 / 2.01 (C)	0.73 / 1.36 (D)
2	1.41 / 0.71 (B)	0.71 / 1.42 (E)
3	∞ / 0.00 (A)	0.30 / 3.33 (F)

- **Grupo A** - De -13.9 a 0.6
- **Grupo B** - De 0.6 a 15.2
- **Grupo C** - De 15.2 a 29.7
- **Grupo D** - De 29.7 a 44.2
- **Grupo E** - De 44.2 a 58.8
- **Grupo F** - De 58.8 a 73.3

Figura 9: Tabla de resumen de las oportunidades o chances de supervivencia dado el bloque de edad

1.1.7. Por cantidad de familiares

En la **Figura 10** se observa que la no supervivencia se agudiza en el centro (edad promedio) y si hay un efecto de equilibrio en los extremos, incluso siendo mayor la supervivencia en niños.




Figura 10: Efecto de la supervivencia por cantidad de familia (x_5)

Familiares: 0

=====

Chances sobrevive: 163 a 374 (0.44)

Chances no sobrevive: 374 a 163 (2.29)

Familiares: 1

=====

Chances sobrevive: 89 a 72 (1.24)

Chances no sobrevive: 72 a 89 (0.81)

Familiares: 2

=====

Chances sobrevive: 59 a 43 (1.37)

Chances no sobrevive: 43 a 59 (0.73)

Familiares: 3

```

=====
Chances sobrevive: 21 a 8 (2.62)
Chances no sobrevive: 8 a 21 (0.38)

Familiares: 4
=====
Chances sobrevive: 3 a 12 (0.25)
Chances no sobrevive: 12 a 3 (4.00)
...
=====
Chances sobrevive: 0 a 7 (0.00)
Chances no sobrevive: 7 a 0 (inf)

```

Aquí se observa que la gran mayoría viajaba sola y tiene altos chances de no sobrevivir, luego esto se invierte de 1 a 3 familiares (familias pequeñas) y se revierte nuevamente con más de 4 familiares (familias grandes). Esto podría ser porque quizás las familias grandes eran de tercera clase, o simplemente fue más difícil tomar una decisión de separarse, pero esto solo es especulativo, habría que formalizarlo en una hipótesis.

Podemos resumir las oportunidades de sobrevivir por cantidad de familia como en la **Figura 11**.

Chances de supervivencia por edad ($\mu \approx 29.7$, $\sigma \approx 14.5$)		
Sigma	Chances Abajo (Sobrevive / No sobrevive)	Chances Arriba (Sobrevive / No sobrevive)
1	0.50 / 2.01 (C)	0.73 / 1.36 (D)
2	1.41 / 0.71 (B)	0.71 / 1.42 (E)
3	∞ / 0.00 (A)	0.30 / 3.33 (F)

- **Grupo A** - De -13.9 a 0.6
- **Grupo B** - De 0.6 a 15.2
- **Grupo C** - De 15.2 a 29.7
- **Grupo D** - De 29.7 a 44.2
- **Grupo E** - De 44.2 a 58.8
- **Grupo F** - De 58.8 a 73.3

Figura 11: Tabla de resumen de las oportunidades o chances de supervivencia dada la cantidad de familia

1.1.8. Con cabina

En la **Figura 12** se observa que de los que sobreviven, hay un poco más de ellos que no tienen cabina, esto será más importante que saber que

sobreviven más veces los que tenían cabina a los que no tenían.




Figura 12: Efecto de la supervivencia si tiene cabina (x_6)

Con cabina: 204 de 891 (22.9%)

Sin cabina: 687 de 891 (77.1%)

Sobreviven con cabina: 136 de 891 (15.3%)

No sobreviven con cabina: 68 de 891 (7.6%)

Sobreviven y con cabina: 136 de 342 (39.8%)

Sobreviven y sin cabina: 206 de 342 (60.2%)

No sobreviven y con cabina: 68 de 549 (12.4%)

No sobreviven y sin cabina: 481 de 549 (87.6%)

Chances de sobrevivir con cabina: 3.21

Chances de sobrevivir global: 0.62

Aquí hay algo importante, de los que sobreviven 60 % tenía cabina y cerca del 40 % si tenía cabina, esto significa que no tener cabina aumenta la supervivencia.

1.1.9. Sin cabina

En la **Figura 13** se observa de forma inversa cuando la característica de tener cabina se niega, para entender su contraparte (no tener cabina).




Figura 13: Efecto de la supervivencia si no se tiene cabina ($1 - x_6$)

Sin cabina: 687 de 891 (77.1%)

Con cabina: 204 de 891 (22.9%)

Sobreviven sin cabina: 206 de 891 (23.1%)

No sobreviven sin cabina: 481 de 891 (54.0%)

Sobreviven y sin cabina: 206 de 342 (60.2%)

Sobreviven y con cabina: 136 de 342 (39.8%)

No sobreviven y sin cabina: 481 de 549 (87.6%)

No sobreviven y con cabina: 68 de 549 (12.4%)

Chances de sobrevivir sin cabina: 0.69

Chances de sobrevivir global: 0.62

Podemos ver que de los que no sobreviven, la gran mayoría no tenía cabina, pero esto no es concluyente ni se puede entender fácilmente.

Podemos resumir las oportunidades de sobrevivir teniendo cabina como en la **Figura 14**.

Chances de supervivencia por cabina		
Clase	Chances (Sobrevivir)	Inverso (No sobrevivir)
Todas	0.62	1.61
Con cabina	3.21	0.31
Sin cabina	0.69	1.45

Figura 14: Tabla de resumen de las oportunidades o chances de supervivencia dado si se tiene cabina

2. La Curva Logística

La *Curva Logística* no es muy diferente del *Modelo de Regresión Lineal*, partimos del mismo predictor lineal $X \cdot \beta$, el cual funciona como un ponderador que transforma cada $X_i \rightarrow x^{(i)}$ en un escalar de predicción z , donde las β funcionan como pesos que regulan o transforman los valores de cada $x_j^{(i)}$

$$z^{(i)} = \beta_0 + x_1^{(i)} \cdot \beta_1 + x_2^{(i)} \cdot \beta_2 + \dots + x_k^{(i)} \cdot \beta_k \quad (2)$$

Y para todas las X , es decir, todas las $i = 1, 2, \dots, n$ podemos usar la representación matricial y vectorial

$$z = X \cdot \beta \quad (3)$$

Donde $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_k)$ representan los coeficientes de regresión, que podemos interpretar como parámetros que se ajustan para llevar a $x^{(i)} \in \mathbb{R}^k$ al escalar $z^{(i)} \in \mathbb{R}$. Además X es la matriz de diseño que incluye una columna de unos para considerar a β_0 que representa el *bias* o interceptor, relacionado a cuando las características no aportan información, es decir, $X = (1; x_1; x_2; \dots; x_k)$, con $x_j = (x_j^{(1)}, x_j^{(2)}, \dots, x_j^{(n)})^\top$ el vector de la característica j en todas las n observaciones ($i = 1, 2, \dots, n$ y $j = 1, 2, \dots, k$).

$$X = \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_k^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_k^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & x_2^{(n)} & \dots & x_k^{(n)} \end{pmatrix} \quad (4)$$

Entonces, podemos entender la matriz de diseño como vectores fila $X_i = (1, x_1^{(i)}, x_2^{(i)}, \dots, x_k^{(i)})$, o vectores columna $X_0 = 1_n$ y $X_j = x_j$, con $x_j = (x_j^{(1)}, x_j^{(2)}, \dots, x_j^{(n)})^\top$. Entonces, entendemos el vector z de escalar de predicción como:

$$z = \begin{pmatrix} z_1 \\ z_2 \\ \dots \\ z_n \end{pmatrix} = \begin{pmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_k^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_k^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_1^{(n)} & x_2^{(n)} & \dots & x_k^{(n)} \end{pmatrix} \cdot \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \dots \\ \beta_k \end{pmatrix} \quad (5)$$

De aquí es donde deducimos que:

$$\begin{aligned}
 z_i &= \begin{pmatrix} 1 & x_1^{(i)} & x_2^{(i)} & \dots & x_k^{(i)} \end{pmatrix} \cdot \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \dots \\ \beta_k \end{pmatrix} \\
 &= \beta_0 + x_1^{(i)} \cdot \beta_1 + x_2^{(i)} \cdot \beta_2 + \dots + x_k^{(i)} \cdot \beta_k
 \end{aligned} \tag{6}$$

En el *Modelo de Regresión Lineal*, entendemos el vector de predicciones z como la respuesta de predicción $\hat{y}$, es decir, el modelo se ve como:

$$y \approx \hat{y} = X \cdot \beta = z \tag{7}$$

Entonces, podemos pensar que hay una función de respuesta $\Phi(z) = z$, o mejor aún, usando el predictor lineal directamente $\Phi(X \cdot \beta) = X \cdot \beta$.

Con esto podemos diseñar un modelo general

$$y \approx \hat{y} = \Phi(X \cdot \beta) \tag{8}$$

El cual entenderemos como el *Modelo Lineal Generalizado*, que se basa construir una respuesta de predicción a partir de un predictor lineal, es decir, las características observadas sometidas a pesos ajustados. Así logramos un modelo general de aprendizaje que proyecta la percepción lineal ponderada por pesos ajustados y sometidos a una función de activación, formando así el *Modelo del Perceptrón*.

$$y \approx \hat{y} = \text{Perceptron}(\Phi, X \cdot \beta) \tag{9}$$

Ahora, entendemos que el perceptrón utiliza una función o curva de activación como núcleo o corazón central para realizar las predicciones, sin embargo, el perceptrón se limita a dar respuestas tan buenas o malas como se hayan ajustado los pesos β .

Podemos pensar que la función de activación o curva $\Phi(X \cdot \beta) = \Phi(z)$ con $z = X \cdot \beta$, toma un escalar z y transforma el valor en una respuesta, es decir, $\Phi(z) : \mathbb{R} \rightarrow \mathbb{R}$ lleva una percepción $z \in \mathbb{R}$ a una respuesta $\hat{y} \in \mathbb{R}$.

$$\hat{y} = \Phi(X \cdot \beta) = \Phi(z) \tag{10}$$

Entonces, podemos pensar en la función de activación Φ como una predicción lineal o una predicción logística:

- *Curva lineal* - $\Phi(z) = z$
- *Curva logística* - $\Phi(z) = \phi(z) = \frac{\exp(z)}{1+\exp(z)} = \frac{1}{1+\exp(-z)}$

Aquí es donde el modelo de regresión por *Curva Logística* toma sentido, porque si pensamos en el espacio de predicciones $z = X \cdot \beta$ pensamos en $z \in \mathbb{R}$ o prácticamente $z \in (-\infty, \infty)$, es decir, las características se mapean mediante los pesos β en todo el espacio de predicción, pero $\phi(z) \in (0, 1)$, es decir, la predicción sobre z , queda limitada la imagen de la función de activación $\Phi(z) = \phi(z)$, que al ser una curva logística estará dentro de $(0, 1)$.

Por eso, es común pensar que la curva logística sirve para hacer predicciones de una respuesta y en un espacio binario o probabilístico, ya que la predicción $\hat{y} = \Phi(X\beta)$ quedará limitada al espacio $(0, 1)$. Por esto mismo, diremos que el modelo de la curva logística resuelve un problema de respuesta cerrada.

Nota: Si la respuesta fuera categórica, entonces podemos hacer que cada respuesta prediga si las características pertenecen o no a una sola categoría, volviéndolo un problema de clasificación multibinaria, por ejemplo, con 3 categorías A, B, C podemos crear 3 perceptrones de curva logística, $Perceptron_A = (\phi, X \cdot \beta_A)$, $Perceptron_B = (\phi, X \cdot \beta_B)$ y $Perceptron_C = (\phi, X \cdot \beta_C)$, donde cada perceptrón hará la predicción si X representa o no la categoría A , si representa o no la categoría B o si representa o no la categoría C de forma independiente. Y cuando solo hay una categoría como la supervivencia, podemos con un único perceptrón predecir si se sobrevivirá o no (pertenece o no a la única categoría). Otras adaptaciones pueden permitir que si la respuesta y pertenece al intervalo $[a, b]$ se pueda normalizar para predecir la respuesta en $[0, 1]$.

2.1. Ejemplo 2 - Cubo de datos para la supervivencia

Ahora podemos establecer con estos conceptos un perceptrón del modelo de la curva logística para la supervivencia con los datos del Titanic. Primero definimos la matriz de diseño X con las 6 características como en la **Figura 15**.

```

1 X = numpy.array([
2     numpy.zeros_like(x1) + 1,
3     x1, x2, x3,
4     x4, x5, x6,
5 ]) .T
6
7 pandas.DataFrame(X)
```

	0	1	2	3	4	5	6
0	1.0	0.0	0.0	0.0	-0.530005	1.0	0.0
1	1.0	1.0	0.0	1.0	0.571430	1.0	1.0
2	1.0	0.0	0.0	1.0	-0.254646	0.0	0.0
3	1.0	1.0	0.0	1.0	0.364911	1.0	1.0
4	1.0	0.0	0.0	0.0	0.364911	0.0	0.0
...	...	...	...	...	...	...	...
886	1.0	0.0	1.0	0.0	-0.185807	0.0	0.0
887	1.0	1.0	0.0	1.0	-0.736524	0.0	1.0
888	1.0	0.0	0.0	1.0	-0.116967	3.0	0.0
889	1.0	1.0	0.0	0.0	-0.254646	0.0	1.0
890	1.0	0.0	0.0	0.0	0.158392	0.0	0.0

891 rows x 7 columns

Figura 15: Matriz de diseño para las 6 características del Titanic

Recordando que las características $x_1, x_2, \dots, x_6$ representan:

- x_1 - Si el pasajero pertenece a la primera clase
- x_2 - Si el pasajero pertenece a la segunda clase
- x_3 - Si el pasajero es mujer
- x_4 - La edad normalizada del pasajero
- x_5 - La cantidad de familiares con las que viajaba el pasajero
- x_6 - Si el pasajero cuenta con cabina

Además de y , que es la respuesta binaria de si sobrevive (la única categoría que indica si hay o no supervivencia).

2.1.1. Partición de los datos de entrenamiento y pruebas

Para poder evaluar el modelo, no podemos ajustar los pesos β con todos los datos, debemos tomar únicamente un porcentaje de los datos que permita

hacer el ajuste y reservar los datos restantes para realizar las pruebas y deducir las métricas de evaluación, con los que determinemos si el desempeño del modelo es bueno o se sobreajusta.

Con esto tendremos un X_{train} y X_{test} , además de y_{train} y y_{test} . En este caso dejamos 120 observaciones para hacer las pruebas como en la **Figura 16**.

```
1 from sklearn.model_selection import train_test_split
2
3 X_train, X_test, y_train, y_test = train_test_split(X, y
4     , test_size=120)
5
6 print(f"X          -> {X.shape}")
7 print(f"X_train    -> {X_train.shape}")
8 print(f"X_test     -> {X_test.shape}")
9
10 print()
11 print(f"y          -> {y.shape}")
12 print(f"y_train     -> {y_train.shape}")
13 print(f"y_test      -> {y_test.shape}")
```

```
X          -> (891, 7)
X_train    -> (771, 7)
X_test     -> (120, 7)

y          -> (891,)
y_train    -> (771,)
y_test     -> (120,)
```

Figura 16: Partición de los datos en entrenamiento y pruebas

Observa que mientras la matriz X con todas las observaciones tiene 891 datos, la matriz de entrenamiento X_{train} solo tendrá 771 datos, estos seleccionados de forma aleatoria y en el mismo orden que y_{train} , por lo que supondremos que es la matriz completa mientras hagamos el ajuste de los parámetros β .

2.1.2. Optimizador ingenuo

Para poder encontrar los parámetros β usaremos un optimizador, en este caso el optimizador ingenuo, que es en realidad un optimizador estocástico

simple, el cual parte de $\beta^* \sim \text{Normal}(1, \sigma)$, con σ pequeño y constante. Luego para las β^+ que son pesos alternativos a las supuestas óptimas, tenemos $\beta^+ \sim \text{Normal}(\beta^*, \sigma)$, o simplemente $\beta^+ = \beta^* + \varepsilon$ una pequeña perturbación al rededor de los pesos que se suponen óptimos hasta ese momento en cada iteración.

Consulta el artículo sobre la optimización estocástica:

https://perso.esiee.fr/~chierchg/optimization/content/02/cross_entropy.html

```
1 betas_opt = numpy.random.normal(  
2     1,  
3     0.1,  
4     X_train.shape[1]  
5 ) # X_train.shape[1] = 7 características  
6  
7 betas1 = betas_opt.copy()  
8  
9 errores = []  
10  
11 for i in range(1_000):  
12     # Betas alternativas, las betas optimas  
13     # mas una perturbacion  
14     betas_alt = (  
15         betas_opt +  
16         numpy.random.normal(0, 0.1, X_train.shape[1])  
17     )  
18  
19     # Prediccion del modelo con las betas optimas  
20     yp_opt = (  
21         numpy.exp(X_train.dot(betas_opt)) /  
22         (1 + numpy.exp(X_train.dot(betas_opt)))  
23     )  
24  
25     # Prediccion del modelo con las betas alternativas  
26     yp_alt = (  
27         numpy.exp(X_train.dot(betas_alt)) /  
28         (1 + numpy.exp(X_train.dot(betas_alt)))  
29     )  
30  
31     # Error de entropia cruzada para la prediccion  
32     # usando las betas optimas
```

```

33     e_opt = -(
34         y_train * numpy.log(yp_opt) +
35         (1 - y_train) * numpy.log(1 - yp_opt)
36     ).mean()
37
38     # Error de entropia cruzada para la prediccion
39     # usando las betas alternativas
40     e_alt = -(
41         y_train * numpy.log(yp_alt) +
42         (1 - y_train) * numpy.log(1 - yp_alt)
43     ).mean()
44
45     # Actualizacion de las betas si hay mayor error
46     # en la prediccion optima que en la alternativa
47     if e_opt > e_alt:
48         betas_opt = betas_alt
49         e_opt = e_alt
50
51     # Guardamos el historico de los errores optimos
52     errores.append(e_opt)
53
54     betas2 = betas_opt.copy()
55
56     print("Error optimo", e_opt)
57
58     pandas.DataFrame({
59         "betas_inicio": betas1,
60         "betas_final": betas2
61     })

```

Los resultados de la optimización se muestran en la **Figura 17**. En la tabla se muestran los β^* iniciales que son valores aleatorios cercanos a uno, y luego los β^* que son los pesos alcanzados tras 1,000 épocas o iteraciones.

Dado que en cada época se compara el error de predicción sobre las β^* (pesos óptimos hasta el momento) y las β^+ (pesos alternativos al óptimo), podemos observar una especie de elitismo, donde se preserva la mejor solución en la iteración, la cual es sensible a quedarse en un mínimo local. La decisión de partir de un valor cercano a 1, es suponer que cada característica aportará de forma directa la respuesta, luego las β_j se irán ajustando para cada característica hasta obtener los β^* finales que tengan el menor error de pérdida posible, usando la entropía cruzada binaria, dado que la respuesta vive en el espacio $(0, 1)$.

Error óptimo 0.4415270881037421

	betas_inicio	betas_final
0	0.769437	-2.261825
1	1.124715	1.495584
2	1.034449	1.181339
3	0.833943	2.734199
4	0.987405	-0.435213
5	1.145616	-0.213520
6	1.087544	1.017915

Figura 17: Pesos ajustados tras la optimización

Llegando así a la solución $\beta = (-2,26, 1,49, 1,18, 2,73, -0,43, -0,21, 1,01)$ que representa a $\beta_0, \beta_1, \beta_2, \dots, \beta_6$, asociados al *bias*, $x_1, x_2, \dots, x_6$.

Entonces interpretamos que el efecto del *bias* (respuesta media no informada) es negativa, esto significa que se espera que la supervivencia disminuya si todas las $x_j = 0$. Para el caso de ser primera o segunda clase la supervivencia aumenta, más aún si se es mujer, pero con un efecto contrario, estar más arriba de la media de edad causará un efecto contrario disminuyendo la supervivencia, lo mismo que viajar con más familiares, aunque de menor efecto y un aumento en la supervivencia si se posee cabina.

Estos valores β se asocian a una *razón de momios* que está relacionada con los chances u oportunidades de cambiar la respuesta (aumentar o disminuir la supervivencia), por lo que $\exp(\beta)$ representa el *odds ratio* o esta *razón de momios*.

Es importante recordar que las oportunidades o chances se entienden mejor si hablamos de incrementar las oportunidades superando el 1, por lo que si el momio es menor a 1, conviene más interpretar su inverso.

```
1 pandas.DataFrame({
2     "beta": betas_opt,
3     "momios": numpy.exp(betas_opt),
4     "momios_inv": numpy.exp(-betas_opt),
5 }) .round(1)
```

En la **Figura 18** se muestran los momios y momios inversos, teniendo:

- $\beta_0^* \leq 0$: $\exp(-\beta_0^*) \approx 9,6$

	beta	momios	momios_inv
0	-2.3	0.1	9.6
1	1.5	4.5	0.2
2	1.2	3.3	0.3
3	2.7	15.4	0.1
4	-0.4	0.6	1.5
5	-0.2	0.8	1.2
6	1.0	2.8	0.4

Figura 18: Razón de momios de las β^*

- $\beta_1^* \geq 0$: $\exp(\beta_1^*) \approx 4,5$
- $\beta_2^* \geq 0$: $\exp(\beta_2^*) \approx 3,3$
- $\beta_3^* \geq 0$: $\exp(\beta_3^*) \approx 15,4$
- $\beta_4^* \leq 0$: $\exp(-\beta_4^*) \approx 1,5$
- $\beta_5^* \leq 0$: $\exp(-\beta_5^*) \approx 1,2$
- $\beta_6^* \geq 0$: $\exp(\beta_6^*) \approx 2,8$

Los directos indican que hay una razón de momios muy fuerte en cuando el pasajero es mujer con $\exp(\beta_3^*) \approx 15,4$, y de forma contraria si un pasajero está una desviación estándar arriba de la media de su edad, entonces la razón de momios indica una caída relacionada a la supervivencia de $\exp(-\beta_4^*) \approx 1,5$, aunque no se debe confundir con los chances directos o las probabilidades de y , dado que estas razones están cruzadas en el modelo.

Lo importante aquí será observar el efecto que tiene cada peso β_j respecto a la supervivencia y si apoyará al incremento o decaída de la respuesta.

3. Las Métricas de Validación

Finalmente, para validar la capacidad de predicción del modelo alcanzado, podemos obtener métricas que nos permitan entender qué tan buenas son las predicciones. Usaremos la matriz de confusión para determinar cuántas predicciones logra identificar correctamente en los datos de prueba, y construir indicadores que nos permitan estimar el porcentaje de exactitud, precisión, sensibilidad, especificidad y desempeño alcanzados.

3.1. Ejemplo 3 - Validación del modelo de supervivencia

Para obtener las predicciones, usaremos la curva logística evaluada en los datos de pruebas y las compararemos contra las respuestas reales como en la **Figura 19**.

```
1 yp_test = (  
2     numpy.exp(X_test.dot(betas_opt)) /  
3     (1 + numpy.exp(X_test.dot(betas_opt)))  
4 )  
5  
6 pandas.DataFrame({  
7     "y_test": y_test,  
8     "yp_test": yp_test,  
9     "yp_test_bin": (yp_test > 0.5).astype(int),  
10 }).round(2)
```

	y_test	yp_test	yp_test_bin
280	0	0.03	0
643	1	0.10	0
362	0	0.45	0
641	1	0.96	1
129	0	0.06	0
...	...	...	...
384	0	0.10	0
432	1	0.74	1
121	0	0.10	0
501	0	0.68	1
192	1	0.64	1

120 rows x 3 columns

Figura 19: Comparación de las respuestas reales contra las predicciones en los datos de prueba

A simple vista se observa que la curva de predicción es $\hat{y}^{(1)} \approx 0,03$, mientras que la respuesta real es $y^1 = 1$ y $\hat{y}^{(2)} \approx 0,10$, mientras que la respuesta real es $y^{(2)} = 1$, lo cual ya empieza a mostrar diferencias. Estas diferencias se visualizan mejor en la matriz de confusión que hace el conteo de los *Verdaderos Positivos (TP)*, *Verdaderos Negativos (TN)*, *Falsos Positivos (FP)* y *Falsos Negativos (FN)*, como se muestra en la **Figura 20**.

```

1 from sklearn.metrics import confusion_matrix
2
3 matriz = confusion_matrix(y_test, yp_test > 0.5)
4
5 seaborn.heatmap(
6     matriz,
7     cmap="Blues",
8     annot=True
9 )

```




Figura 20: Matriz de confusión (TN: 60, FP: 12, FN: 10, TP: 38)

Con esto podemos interpretar mejor que de los 120 datos de pruebas, 60 son predichos como negativos correctamente, mientras que solo 38 son predichos como positivos correctamente. Con esto podemos construir las métricas de desempeño como se muestra en la **Figura 21**.

```

1 accuracy = (tp + tn) / (tp + fp + fn + tn)
2 precision = tp / (tp + fp)
3 sensivity = tp / (tp + fn) # recall
4 specificity = tn / (tn + fp)
5 npv = tn / (tn + fn) # negative predictive value

```

```

6 f1 = 2 * (precision * sensivity) / (precision +
    sensivity) # f1-score
7
8 print(f"Exactitud      = {accuracy:.2f}")
9 print(f"Precision      = {precision:.2f}")
10 print(f"Sensibilidad   = {sensivity:.2f}")
11 print(f"Especificidad = {specificity:.2f}")
12 print(f"F1-Score      = {f1:.2f}")
13 print(f"NPV           = {npv:.2f}")

```

```

Exactitud      = 0.82
Precision      = 0.76
Sensibilidad   = 0.79
Especificidad  = 0.83
F1-Score      = 0.78
NPV           = 0.86

```

Figura 21: Métricas de desempeño

Observando que:

- *Exactitud* $\approx 82\%$
- *Precisión* $\approx 76\%$
- *Sensibilidad* $\approx 79\%$
- *Especificidad* $\approx 83\%$
- *F1-Score* $\approx 78\%$
- *Negative Predictive Value* $\approx 86\%$

Demostrando una capacidad de predicción buena considerando que hablamos de un solo perceptrón o curva que intenta ajustar la respuesta basado únicamente el predictor lineal.

Algo importante a analizar es el umbral utilizado de 0,5 que se tomó de manera empírica, suponiendo que algo mayor a 0,5 es una predicción de 1, mientras que algo menor a 0,5 es una predicción de 0. Sin embargo, es posible mover este umbral, por ejemplo a 0,53 para balancear mejor los falsos positivos y los falsos negativos, llegando a una matriz más simétrica, aunque

a costa de bajar quizás los verdaderos positivos.

Nota: En la libreta de código complementaria a estas notas se analiza de forma más profunda estos resultados y algunas gráficas adicionales que no se muestran aquí, como el espacio de dos componentes formado por el *PCA*.

3.1.1. Gráficas adicionales de análisis

También podemos generar algunas gráficas interesantes para poner en mayor perspectiva el desempeño del modelo e interpretar mejor el comportamiento del predictor lineal.

En la **Figura 22** observamos el comportamiento de la respuesta promedio en 100 intervalos (*bins*) del predictor lineal y la curva logística de la predicción sobre el predictor lineal. A partir del 0 las predicciones serán 1, aquí podemos




Figura 22: Curva logística sobre la respuesta promedio en 100 *bins* y el umbral de 0,5

observar como algunos puntos deberían ser azúles, pero los pinta en naranja y otros deberían ser naranjas pero los pinta azúles, esto está relacionado con los falsos positivos y negativos. Además si cambiamos el umbral a 0,53 ya no será el 0 el punto de corte de la decisión, sino $0,12 = \ln\left(\frac{0,53}{1-0,53}\right)$.

En la **Figura 23** observamos la distribución de los datos que quedan correctamente clasificados y los que no, viendo que los verdaderos negativos

quedan a la izquierda del cero, mientras que los verdaderos positivos quedan a la derecha, sin embargo, se ve una cantidad importante de falsos positivos a la derecha y otra cantidad significativa de falsos negativos a la izquierda.




Figura 23: Histograma de la distribución de verdaderos negativos, falsos positivos, falsos negativos y verdaderos positivos el umbral de 0,5

En la **Figura 24** observamos la distribución en forma de densidades, lo cual permite identificar mejor las regiones de confusión.

En la **Figura 25** observamos la densidad de las predicciones positivas y negativas con el umbral de 0,5, aquí se observa que hay predicciones 1 antes del cero y predicciones 0 después del cero.

En la **Figura 26** observamos la curva *ROC* que indica cómo cambia el compromiso entre sensibilidad y tasa de falsos positivos para diferentes umbrales de decisión, esto se apoya con un *AUC* de 0,85.

4. Tarea 3

Utiliza el conjunto de datos *student_habits_performance.csv* como en la **Tarea 2**, para reproducir resultados similares a los de estas notas, pero para determinar la respuesta *y* si el estudiante tendrá o no una calificación (*exam*




Figura 24: Densidades de la distribución de verdaderos negativos, falsos positivos, falsos negativos y verdaderos positivos usando el umbral de 0,5




Figura 25: Densidades de la predicción usando el umbral de 0,5

score) mayor o igual a 70 (aprobado).

El objetivo de esta tarea es replicar el análisis anterior utilizando la mayor




Figura 26: Curva *ROC* de las predicciones y la respuesta real

cantidad de características del estudiante y la puntuación del examen como la respuesta y (pero en forma binaria $exam_{score} \geq 70$).

Resuelve los siguientes puntos:

- Carga el conjunto de datos *student_habits_performance.csv* disponible en la carpeta de *conjuntos* del repositorio del curso.
- Construye la matriz de características X utilizando todas las características que consideres, no olvides incluir el vector de unos para el *bias*.
- Determina el vector de respuesta y usando la columna *exam_score* mayor o igual a 70.
- Separa la matriz de características y el vector de respuesta en X_{train} , X_{test} , y_{train} , y_{test} .
- Termina de replicar todo el análisis. Consulta las libretas del repositorio:

`ejemplos/s301/e301_01.ipynb`
`ejemplos/s301/e301_02.ipynb`

Notas:

1. Considera que la puntuación del examen es aprobatoria con sila clasificación es mayor o igual a 70
2. Analiza cuidadosamente los efectos que tiene cada característica que propones, por ejemplo, las horas de estudio deberían tener un efecto positivo, mientras que las horas de ocio uno negativo.

4.1. Preguntas de análisis

Contesta las siguientes preguntas de análisis:

1. ¿Cuáles son los valores de las β ?
2. ¿Cuáles son los valores de los momios derivados de las β ?
3. ¿Qué indican las métricas obtenidas?
4. ¿Consideras que fue un buen ajuste de la predicción o no es suficiente? Justifica tu respuesta

Nota: La tarea se deberá entregar en formato PDF con las fotos o captura de pantalla de los resultados, no es necesario mostrar el código. No olvides poner tu nombre y las repuestas a las preguntas de análisis.

5. Conclusiones

En esta sesión hemos finalizado el análisis de los dos modelos principales de regresión, la regresión lineal de la sesión anterior nos permitió entender el efecto de un predictor lineal sobre una respuesta abierta, mientras que la curva logística cierra las predicciones en el espacio $(0, 1)$, con esto ahora nos podemos enfrentar a problemas de regresión en el espacio abierto de la respuesta, o probelmas de clasificación en espacios cerrados de respuestas binarias o multibinarias (una curva de predicción para cada respuesta / categoría).

Bibliografía

- Géron, A. (2023). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3.^a ed.). O'Reilly Media.

- Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media.
- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter (3.^a ed.). O'Reilly Media.
- Grus, J. (2019). Data Science from Scratch: First Principles with Python (2.^a ed.). O'Reilly Media.

Nota: Consulta el libro de Python for Data Analysis de Wes McKinney.